


Time To First Token wobec kontekstu RAG



Mechanizm: k -> rozmiar promptu -> czas prefill

